

TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Projeto em Business Intelligence e Analytics
Fase 2

Nome do estudante: Rodrigo Santana Lopes

1. Métricas para o negócio proposto (KPIs):

A solução de BI foi desenvolvida para acompanhar o desempenho comercial de uma empresa fictícia. Os indicadores foram definidos com base nos dados de pedidos, vendas, clientes, produtos, regiões e canais de atendimento.

Os principais KPIs utilizados foram:

1. **Receita total:** correspondeu à soma da receita líquida dos pedidos concluídos. Esse indicador permitiu acompanhar quanto a empresa gerou em vendas durante o período analisado.
2. **Lucro total:** correspondeu à diferença entre a receita líquida e os custos relacionados às vendas. Esse indicador apresentou o resultado financeiro obtido pela empresa.
3. **Margem de lucro:** representou o percentual do lucro em relação à receita total. Seu cálculo foi realizado pela divisão do lucro total pela receita total.
4. **Quantidade vendida:** correspondeu à soma das unidades vendidas nos pedidos concluídos. Esse indicador permitiu analisar o volume de produtos comercializados.
5. **Total de pedidos:** apresentou a quantidade total de pedidos registrados na base, incluindo pedidos concluídos, cancelados e devolvidos.
6. **Pedidos concluídos:** mostrou a quantidade de pedidos que foram finalizados com sucesso.
7. **Taxa de conclusão:** representou o percentual de pedidos concluídos em relação ao total de pedidos registrados.
8. **Ticket médio:** indicou o valor médio de cada pedido concluído. O cálculo foi realizado pela divisão da receita total pela quantidade de pedidos concluídos.
9. **Clientes únicos:** apresentou a quantidade de clientes diferentes que realizaram pedidos concluídos.
10. **Receita por região:** permitiu comparar o desempenho comercial entre as regiões Sudeste, Sul, Nordeste, Centro-Oeste e Norte.
11. **Receita por categoria:** mostrou quais categorias de produtos e serviços geraram maior receita.
12. **Receita por canal:** permitiu analisar o desempenho das vendas realizadas pelos canais online, loja física, representante e telefone.
13. **Evolução mensal da receita:** apresentou o comportamento das vendas ao longo dos meses e permitiu identificar períodos de crescimento ou queda.

Além dos indicadores principais, foram criadas **visões comerciais, operacionais e de risco (preferi separar)**. A visão comercial apresentou os resultados por região, categoria, canal, produto e vendedor. A visão operacional permitiu acompanhar os pedidos concluídos, cancelados e devolvidos. A visão de risco utilizou os resultados do modelo de machine learning desenvolvido para identificar pedidos com maior probabilidade de não conclusão.

2. Arquitetura da solução (ferramentas, pipeline com as fases, repositórios, dependências):

A arquitetura da solução foi organizada para integrar a geração dos dados, o tratamento das informações, a construção dos dashboards, a análise preditiva e o armazenamento dos arquivos do projeto.

A primeira etapa consistiu na geração de uma base fictícia de vendas por meio da linguagem Python. A base foi composta por 2.500 registros e reuniu informações como data do pedido, cliente, vendedor, região, categoria, produto, canal de venda, status do pedido, quantidade, receita bruta, receita líquida, custo e lucro.

Durante o processamento em Python, os dados foram organizados e utilizados para gerar arquivos no formato CSV. Além da base principal de vendas, foram criados arquivos resumidos com indicadores mensais e análises por região, categoria e canal.

O arquivo principal foi utilizado como fonte de dados no Power BI. Nessa ferramenta, foram criadas medidas, indicadores e visualizações para acompanhar o desempenho financeiro, comercial e operacional da empresa fictícia. O dashboard foi dividido em páginas voltadas para a visão executiva, desempenho comercial, análise operacional, risco de pedidos e desempenho do modelo preditivo.

A análise preditiva foi desenvolvida no Google Colab com o uso da linguagem Python. Foi utilizado um modelo de Regressão Logística para estimar a probabilidade de cada pedido ser concluído ou não.

A variável alvo foi denominada `pedido_concluido`. Os pedidos concluídos receberam o valor 1, enquanto os pedidos cancelados ou devolvidos receberam o valor 0.

As variáveis utilizadas pelo modelo foram mês, região, categoria, produto, canal, vendedor, quantidade e receita bruta. As variáveis categóricas foram transformadas em valores numéricos por meio da técnica One Hot Encoding, enquanto as variáveis numéricas foram padronizadas antes do treinamento.

A base foi dividida entre dados de treino e teste. Foram utilizados 70% dos registros para o treinamento do modelo e 30% para sua avaliação. A divisão foi realizada de forma estratificada para manter a proporção das classes nos dois conjuntos.

A Regressão Logística foi escolhida por ser um algoritmo de classificação simples, de fácil interpretação e adequado ao objetivo de estimar a probabilidade de conclusão dos pedidos. O modelo também permitiu analisar os coeficientes das variáveis e identificar quais características apresentaram maior influência nas previsões.

Após o treinamento, foram gerados arquivos CSV contendo as probabilidades de conclusão, o risco de não conclusão, a classificação do risco, as métricas do modelo e a importância das variáveis. Esses arquivos foram posteriormente importados no Power BI para a criação das páginas relacionadas ao risco dos pedidos e ao desempenho do modelo.

As principais bibliotecas utilizadas no Google Colab foram:


- A. Pandas:** leitura e manipulação dos dados.
- B. NumPy:** apoio às operações numéricas.
- C. Scikit-learn:** criação, treinamento e avaliação do modelo de Regressão Linear.
- D. Matplotlib:** visualização dos valores reais e previstos.

A solução também seguiu a determinada sequência abaixo, sendo possível visualizar noo GitHub como repositório dos códigos, arquivos, documentação e materiais produzidos durante o projeto.

O pipeline executado seguiu esta sequência:

1. Geração da base fictícia em Python.
2. Limpeza, organização e processamento dos dados.
3. Criação dos arquivos CSV.
4. Importação dos dados no Power BI.
5. Criação das métricas e dos dashboards.
6. Importação da base preditiva no Google Colab.
7. Treinamento e avaliação do modelo de Regressão Linear.
8. Geração da previsão de receita.
9. Armazenamento dos códigos e da documentação no GitHub.

A arquitetura pode ser representada pelo seguinte fluxo:



3. Solução de BI:

Link repo **GITHUB**:

<https://github.com/RodrigoSantanaLopes/projeto-bi-analytics/tree/projeto>


A solução implementada utilizou uma base fictícia de vendas criada em Python. O conjunto de dados foi composto por 2.500 registros e representou operações comerciais realizadas entre janeiro e dezembro de 2025.

A base reuniu informações sobre pedidos, clientes, vendedores, regiões, categorias, produtos, canais de venda, quantidade, receita, custos e lucro. Também foram incluídos pedidos concluídos, cancelados e devolvidos, permitindo analisar o desempenho comercial e a situação das vendas.

Durante o processamento dos dados, foram gerados arquivos CSV específicos para cada etapa do projeto. A base principal foi utilizada no Power BI para permitir análises detalhadas e aplicação de filtros. Também foram geradas bases resumidas com informações mensais e resultados agrupados por região, categoria e canal.

O dashboard foi construído no Power BI e dividido em cinco áreas principais: **visão executiva**, **desempenho comercial**, **análise operacional**, **risco de pedidos** e **desempenho do modelo**


A **primeira** área apresentou uma visão executiva do negócio. Nela, foram exibidos os principais indicadores da empresa fictícia, como receita total, lucro total, margem de lucro, quantidade vendida, ticket médio e taxa de conclusão dos pedidos.



Essa página também apresentou a evolução mensal da receita e a distribuição dos pedidos por status. Os filtros permitiram analisar os resultados por período, região, categoria, canal e vendedor.


A **segunda** área foi destinada ao desempenho comercial. Nela, foram apresentados gráficos de receita por região, categoria, canal, produto e vendedor. Essa visão permitiu comparar os resultados e identificar quais grupos apresentaram maior participação nas vendas.

| Dashboard - Visão Operacional




Visão analítica

id_pedido	cliente	vendedor	regiao	status_pedido	Soma de receita_bruta	Soma de receita_liquida	Receita Total
960	Cliente 260	Vendedor 4	Sudeste	Concluído	R\$ 8.368.126	R\$ 8.368.126	R\$ 8.368.126
972	Cliente 7	Vendedor 19	Sudeste	Concluído	R\$ 8.040.692	R\$ 8.040.692	R\$ 8.040.692
1025	Cliente 78	Vendedor 14	Sudeste	Concluído	R\$ 7.937.081	R\$ 7.937.081	R\$ 7.937.081
2487	Cliente 57	Vendedor 13	Sudeste	Concluído	R\$ 7.927.243	R\$ 7.927.243	R\$ 7.927.243
280	Cliente 192	Vendedor 5	Sul	Concluído	R\$ 7.854.262	R\$ 7.854.262	R\$ 7.854.262
84	Cliente 224	Vendedor 19	Sudeste	Concluído	R\$ 7.682.066	R\$ 7.682.066	R\$ 7.682.066
465	Cliente 273	Vendedor 8	Sudeste	Concluído	R\$ 7.655.909	R\$ 7.655.909	R\$ 7.655.909
2304	Cliente 22	Vendedor 4	Sudeste	Concluído	R\$ 7.540.449	R\$ 7.540.449	R\$ 7.540.449
2420	Cliente 161	Vendedor 2	Sul	Concluído	R\$ 7.190.615	R\$ 7.190.615	R\$ 7.190.615
1633	Cliente 151	Vendedor 14	Sudeste	Concluído	R\$ 6.927.559	R\$ 6.927.559	R\$ 6.927.559
2239	Cliente 79	Vendedor 3	Nordeste	Concluído	R\$ 6.820.944	R\$ 6.820.944	R\$ 6.820.944
1021	Cliente 298	Vendedor 16	Centro-Oeste	Concluído	R\$ 6.709.274	R\$ 6.709.274	R\$ 6.709.274
Total					R\$ 2.295.282.095	R\$ 2.055.124.950	R\$ 2.022.282.883



A **terceira** área foi voltada para a análise operacional. Foram apresentados o total de pedidos, a quantidade de pedidos concluídos, cancelados e devolvidos, a taxa de conclusão e a quantidade de clientes únicos. Também foram criados gráficos para comparar a situação dos pedidos por mês, canal e categoria.



A **quarta área** apresentou a análise de risco dos pedidos. Essa página utilizou o arquivo gerado pelo modelo de Regressão Logística no Google Colab. Foram exibidos o risco médio de não conclusão, a quantidade de pedidos de alto risco, o percentual de pedidos de alto risco e a probabilidade média de conclusão.

O modelo classificou os pedidos entre concluídos e não concluídos, considerando como não concluídos os pedidos cancelados ou devolvidos. Para cada registro, foram geradas a probabilidade de conclusão, o risco de não conclusão e a classificação do risco em baixo, médio ou alto.

```
Probabilidade de conclusão: 0.3581
Risco de não conclusão: 0.6419
Classificação do risco: Médio
```

Em um dos exemplos analisados, o modelo calculou uma probabilidade de conclusão de 35,81% e um risco de não conclusão de 64,19%. Com base nesse resultado, o pedido foi classificado como de risco médio. Essa informação permitiu demonstrar como o modelo poderia ser utilizado para identificar pedidos que exigem maior atenção da empresa.

Também foram listados os pedidos com menor risco previsto. Nessa análise, alguns registros apresentaram risco de não conclusão entre aproximadamente 14% e 23%, sendo classificados como de baixo risco. A tabela também mostrou que nem todos os resultados previstos coincidiram com o status real do pedido. Alguns pedidos cancelados ou devolvidos foram classificados como de baixo risco, o que revelou limitações no poder de previsão do modelo.

Out[54]:	id_pedido	regiao	categoria	produto	canal	risco_nao_conclusao	classificacao_risco	status_pedido
334	335	Sul	Tecnologia	Mouse	Online	0.141811	Baixo	Concluído
2266	2267	Sudeste	Tecnologia	Impressora	Online	0.151179	Baixo	Concluído
590	591	Centro-Oeste	Tecnologia	Impressora	Online	0.156675	Baixo	Concluído
1328	1329	Sudeste	Tecnologia	Impressora	Loja Física	0.167895	Baixo	Cancelado
1764	1765	Nordeste	Tecnologia	Impressora	Loja Física	0.168519	Baixo	Cancelado
814	815	Norte	Escritório	Pasta	Representante	0.176880	Baixo	Concluído
598	599	Sudeste	Serviços	Treinamento	Representante	0.187894	Baixo	Concluído
1059	1060	Sudeste	Serviços	Treinamento	Representante	0.191897	Baixo	Concluído
2370	2371	Sudeste	Serviços	Consultoria	Representante	0.192551	Baixo	Concluído
602	603	Sudeste	Escritório	Agenda	Loja Física	0.194744	Baixo	Concluído
542	543	Sudeste	Móveis	Gaveteiro	Online	0.196111	Baixo	Concluído
194	195	Sul	Serviços	Treinamento	Representante	0.196525	Baixo	Concluído
1348	1349	Centro-Oeste	Escritório	Agenda	Online	0.196687	Baixo	Devolvido
427	428	Sudeste	Móveis	Cadeira	Online	0.201944	Baixo	Concluído
1461	1462	Sudeste	Serviços	Consultoria	Loja Física	0.217791	Baixo	Concluído
2032	2033	Nordeste	Tecnologia	Mouse	Loja Física	0.219711	Baixo	Concluído
847	848	Sudeste	Tecnologia	Impressora	Loja Física	0.225513	Baixo	Concluído
1825	1826	Sul	Tecnologia	Impressora	Representante	0.226236	Baixo	Concluído
1544	1545	Centro-Oeste	Móveis	Armário	Representante	0.227454	Baixo	Concluído
849	850	Sudeste	Serviços	Consultoria	Loja Física	0.229673	Baixo	Concluído

Out[60]:

	metrica	valor
0	Acurácia	0.5267
1	Precisão	0.8771
2	Recall	0.5393
3	F1-score	0.6679
4	ROC AUC	0.4876

A acurácia obtida foi de 52,67%. Esse resultado indicou que o modelo acertou pouco mais da metade das classificações realizadas na base de teste.

A precisão foi de 87,71%. Esse valor mostrou que, entre os pedidos classificados pelo modelo como concluídos, a maior parte realmente pertencia à classe de pedidos concluídos.

O recall foi de 53,93%. Isso significou que o modelo conseguiu identificar pouco mais da metade dos pedidos que realmente foram concluídos.

O F1-score foi de 66,79%. Essa métrica apresentou um resultado intermediário ao combinar precisão e recall em uma única medida.

O ROC AUC foi de 48,76%. Como esse valor ficou próximo de 50%, o modelo apresentou baixa capacidade de diferenciar pedidos concluídos de pedidos cancelados ou devolvidos.

Os resultados mostraram que o modelo foi executado corretamente, mas apresentou baixo poder de separação entre as classes. Essa limitação ocorreu porque a base utilizada foi fictícia e o status dos pedidos foi gerado de forma aleatória, sem uma relação forte com as demais características da venda.